

## Clustering interactif d'éléments de contenu (extraits de documents)

Encadrant: Jean-Yves Ramel







- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Bilan
- Gestion du projet
- Démonstration





- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Gestion du projet
- **Bilan**
- Démonstration

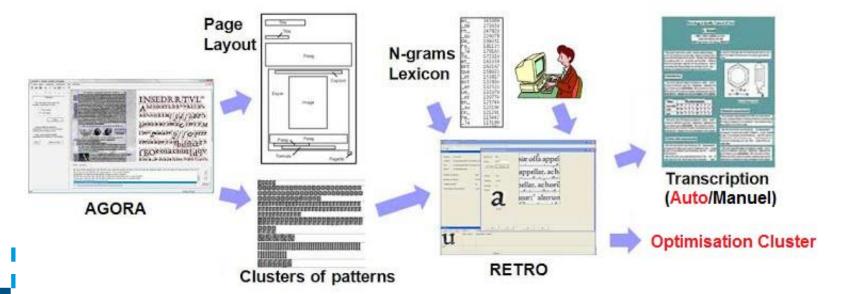


#### Contexte du PFE

POLYTECH'
TOURS

- Contexte: PaRADIIT Project
  - Numérisation de livres anciens
  - Text/graph separation, Optical Character Recognition (OCR), text transcription etc.





#### Contexte du PFE



#### Objectifs:

- ▶ Etude de l'existant: sources, rapports
- Etude des méthodes de Clustering et fouille visuelle de données
- Conception et développement de la visualisation et l'optimisation des clusters
- Conception et développement de la reconnaissance automatiquement de clusters



## Description générale



- Environnement du Développement
  - ▶ IDE: Visual Studio 2012 C#
  - Framework: .Net 4.5
  - Design Pattern: MVVM
- Libraires: AForge, Accord.Net, DynamicDataDisplay
- Outil de gestion de projet: Redmaine Polytech Tours, Git
- Autres outils
  - Logiciel de dessiner IHM: Balsamiq Mockups
  - ▶ Générateur de documentation : SandCastle













- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Gestion du projet
- Bilan
- Démonstration



## Analyse de l'existant



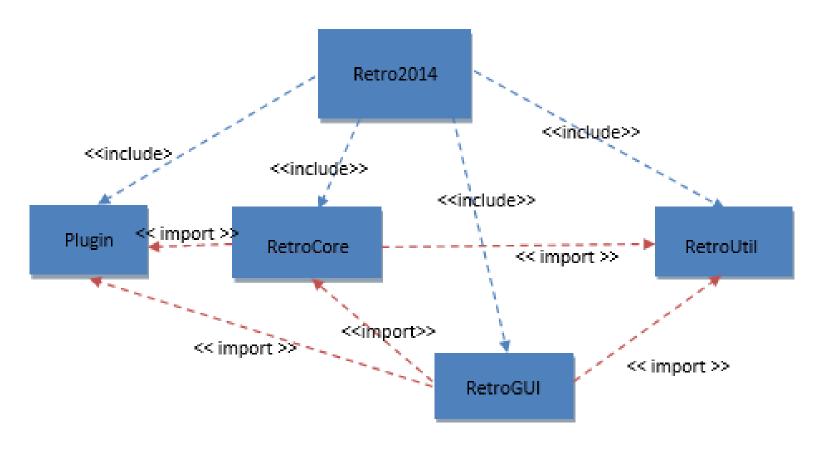
- ▶ Fonctionnalités générale du « Retro2014 »
  - Manipulation du projet
  - Processus du Clustering
  - Transcription Auto/Manuelle
  - Manipulation du document
  - Typographie



## Analyse de l'existant



#### Architecture existant







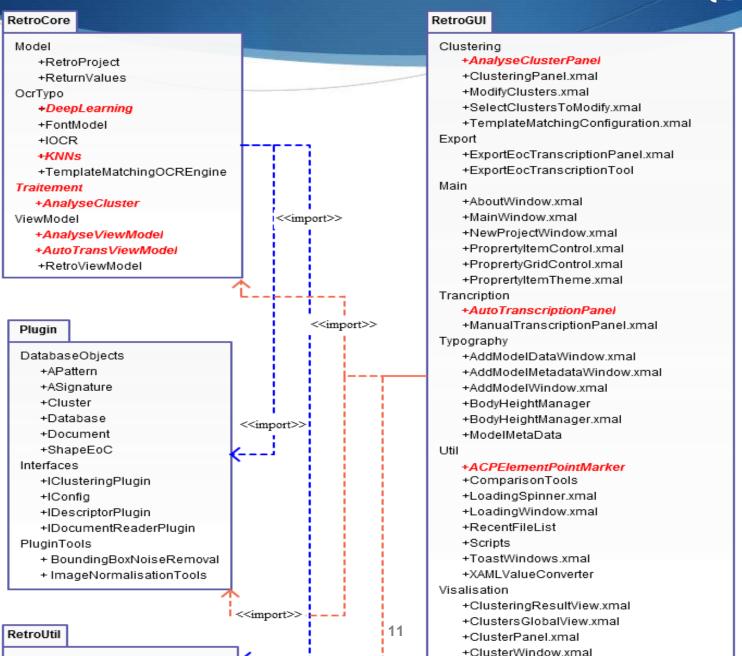
- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Gestion du projet
- **Bilan**
- Démonstration



#### Architecture finale

+DvnamicSplashScreenNotification







- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Gestion du projet
- Bilan
- Démonstration



## Travail réalisé



- La fonctionnalité « Analyse Cluster »
  - Projection des individus par ACP
  - Manipulation interactive des objets projetés
- La fonctionnalité « Transcription Automatique »
  - Exploitation de l'ensemble des éléments du cluster pour mieux le reconnaitre
  - Approche inverse de la méthode classique : Peu de modèles mais de multiples exemples de l'objet à reconnaitre



## Solutions- visuelle de clusters

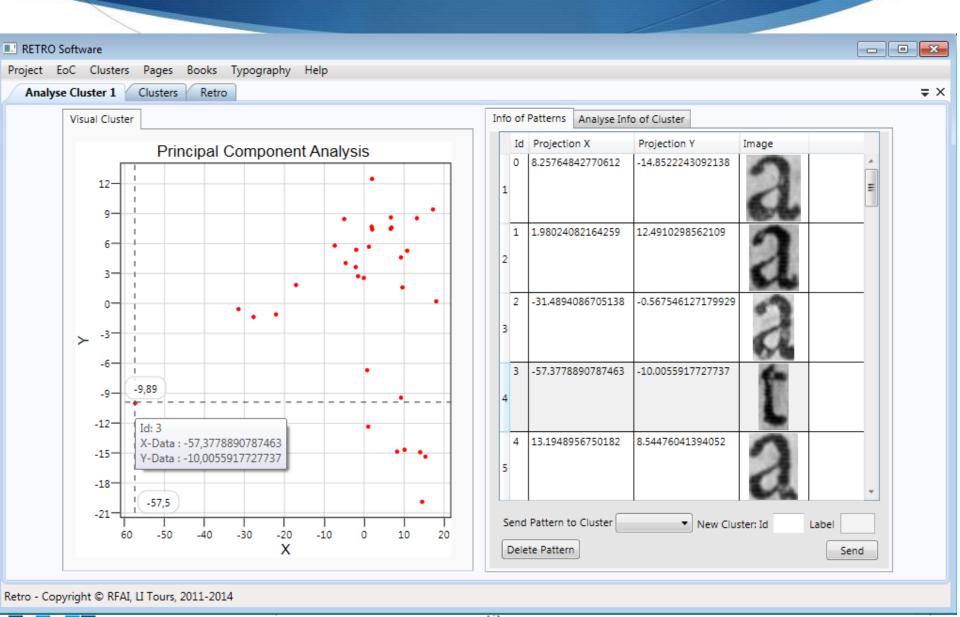


- La fonctionnalité « Analyse Cluster »:
  - Visuelle de clusters
    - ACP + coordonnées dynamique
    - Librairie: Accord.Net, DynamicDataDisplay
  - Optimisation de cluster
    - Manipulations: supprimer, envoyer à l'autre cluster



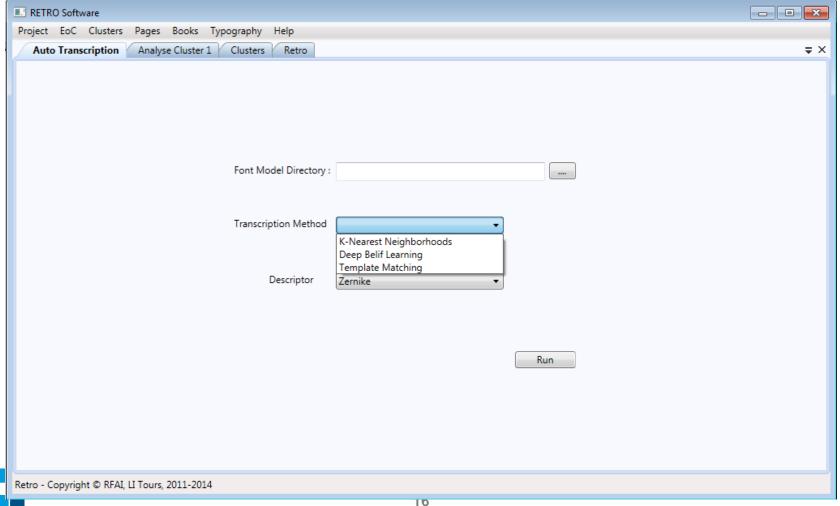
## Solutions- visuelle de clusters







La fonctionnalité « Auto Transcription»





- KPlus Proche Voisins/KNearest Networks (KNNs)
  - L'apprentissage par analogie et l'apprentissage supervisé
  - Apprentissage paresseux

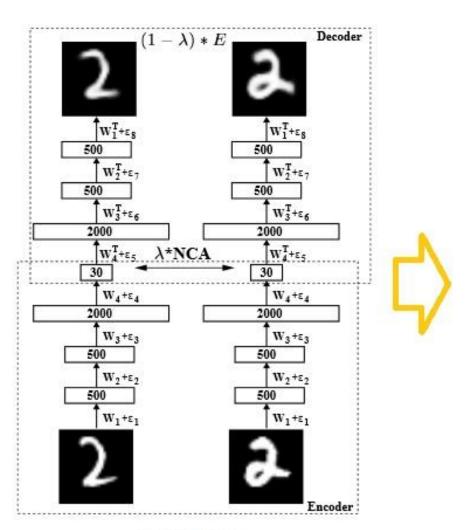




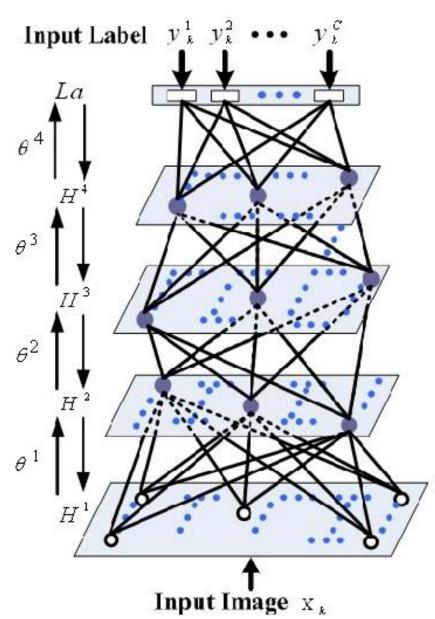
- Apprentissage en profondeur/Deep learning Networks
  - Profondeur = nb de couche
- Modèle probabilistes pour les architectures profondes:
  - Restricted Boltzmann machines(RBMs)
  - Deep Belief Networks(DBNs)





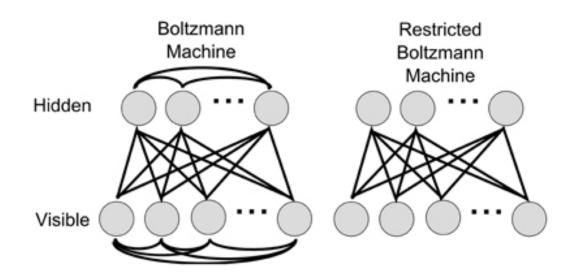


Fine-Tuning





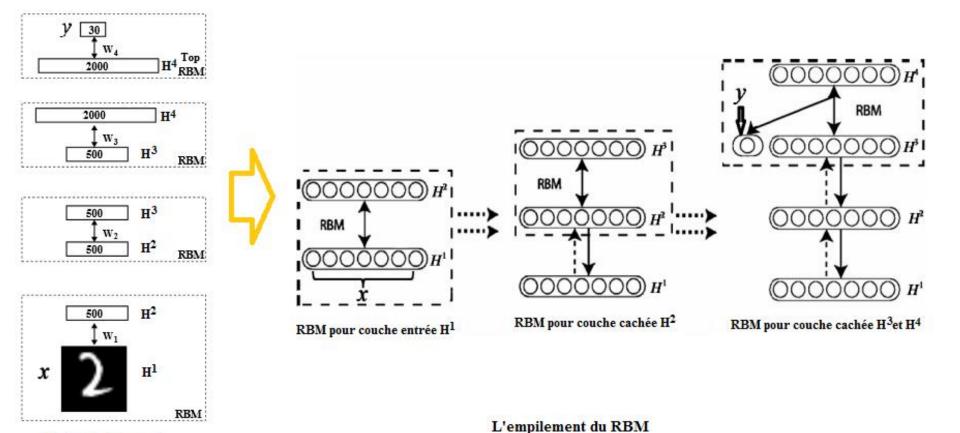
- Restricted Blotzmann Machine(RBM)
  - non-orienté, une couche d'entrée et seule couche cachée

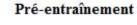






#### DBNs avec RBM

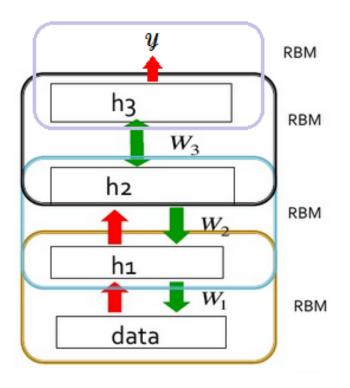


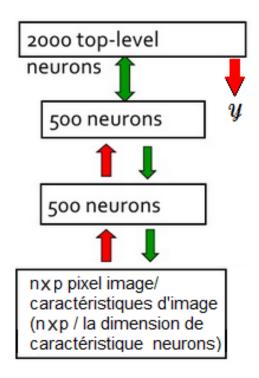


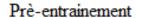




Structure Design du DBNs avec RBM







DBNs





#### Test

Méthode	Base d'app	Base de test	Tps d'app	Tps de test	Tps total	Reco. %
KNNs	70	5	13,0s	22,0s	35s	60%
	180	20	37,4s	35,2s	72,6s	30%
	473	70	61,9s	26,4s	88,3s	11%
DBNs	70	5	19min37s	12,9s	19min50s	0%
	180	20	3h2min	41,2s	3h3min	0%

- Forces et faiblesses
  - Approche tout sorte de fonction
  - Coûteux en apprentissage
  - Effet boite noire





- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- **Bilan**
- Gestion du projet
- Démonstration



## Bilan



- Réalisation des objectifs :
  - Optimisation visuelle cluster
  - ✓ 2 méthodes de l'apprentissage automatique
- Bilan des tests
  - Analyse Cluster: 1000 patterns
  - Transcription : l'effet du KNNs est limit.
    DBNs n'est pas adaptable





- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Bilan
- Gestion du projet
- Démonstration



## Gestion du projet

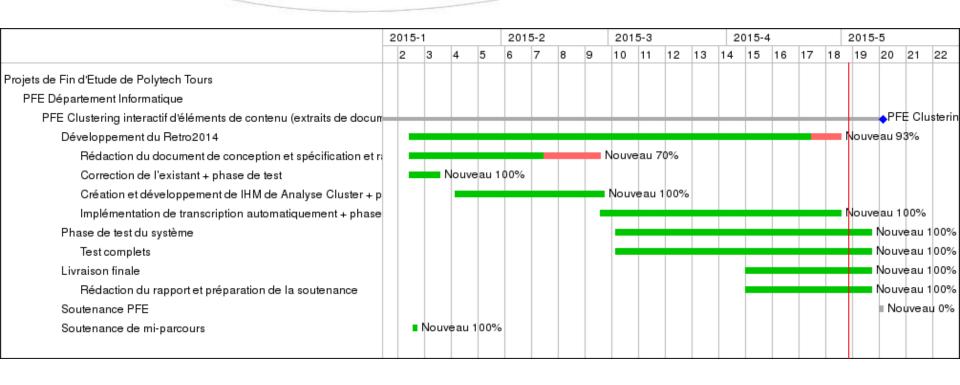


- Difficultés
  - Interactive visuelle de clusters
  - L'implémentation d'algorithme DBNs
- Amélioration
  - L'algorithme d'apprentissage automatique
  - La structure du logiciel



## Gestion du projet





Gant Réel





- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Bilan
- Gestion du projet
- Démonstration



## Démonstration



I. J. RETRO Software	0 2 2
Project EoC Clusters Pages Books Typography Help	
Di Companya di Com	
Retro - Copyright © RFAI, LI Yours, 2011-2014	





# Merci de votre attention! Questions?

