

Clustering interactif d'éléments de contenu (extraits de documents)

Encadrant: Jean-Yves Ramel







- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Bilan
- Gestion du projet
- Démonstration





- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- **▶** Solutions
- Bilan
- Gestion du projet
- Démonstration

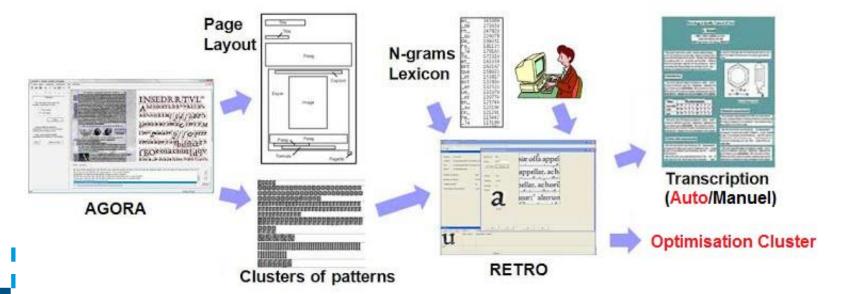


Contexte du PFE

POLYTECH'
TOURS

- Contexte: PaRADIIT Project
 - Numérisation de livres anciens
 - Text/graph separation, Optical Character Recognition (OCR), text transcription etc.





Contexte du PFE



Objectifs:

- ▶ Etude de l'existant: sources, rapports
- Etude des méthodes de Clustering et fouille visuelle de données
- Conception et développement de la visualisation et l'optimisation des clusters
- Conception et développement de la reconnaissance automatiquement de clusters



Description générale



- Environnement du Développement
 - ▶ IDE: Visual Studio 2012 C#
 - Framework: .Net 4.5
 - Design Pattern: MVVM
- Libraires: AForge, Accord.Net, DynamicDataDisplay
- Outil de gestion de projet: Redmaine Polytech Tours, Git
- Autres outils
 - Logiciel de dessiner IHM: Balsamiq Mockups
 - ▶ Générateur de documentation : SandCastle













- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Bilan
- Gestion du projet
- Démonstration



Analyse de l'existant



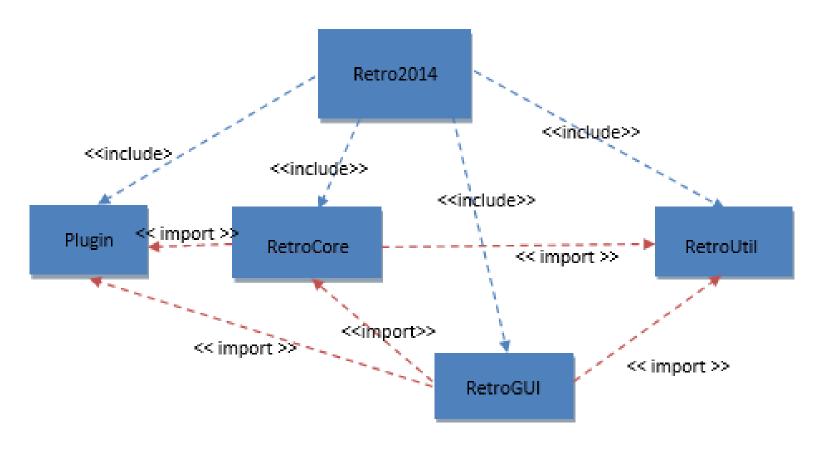
- Fonctionnalités générale du « Retro2014 »
 - Manipulation du projet
 - Processus du Clustering
 - Transcription Auto/Manuelle
 - Manipulation du document
 - Typographie



Analyse de l'existant



Architecture existant

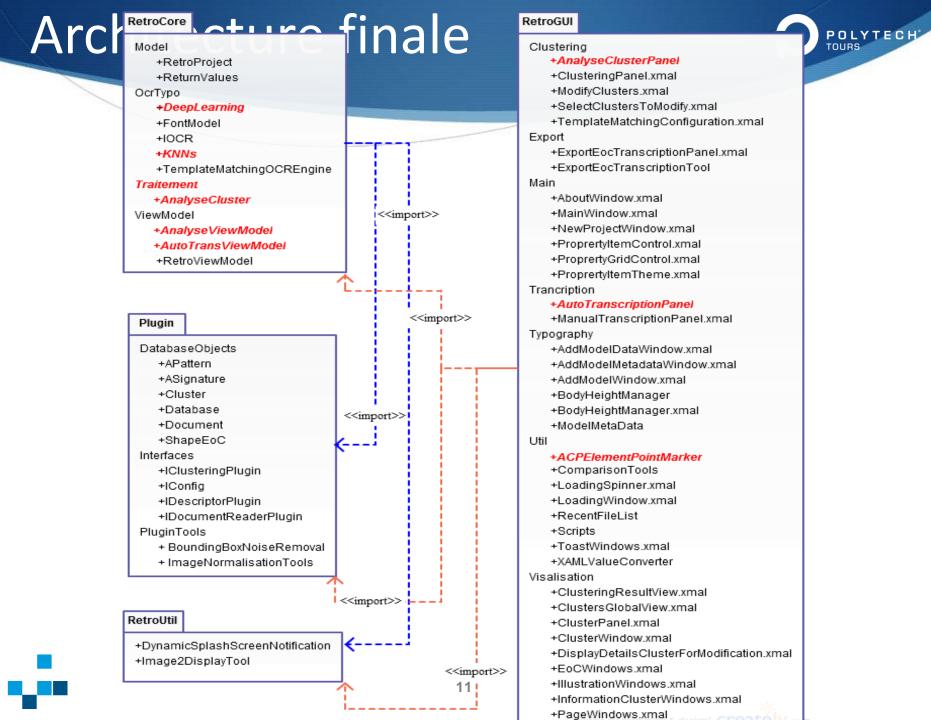






- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Gestion du projet
- **Bilan**
- Démonstration







- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- Gestion du projet
- Bilan
- Démonstration



Travail réalisé



- La fonctionnalité « Analyse Cluster »
 - Projection des individus par ACP
 - Manipulation interactive des objets projetés
- La fonctionnalité « Transcription Automatique »
 - Exploitation de l'ensemble des éléments du cluster pour mieux le reconnaitre
 - Approche inverse de la méthode classique : Peu de modèles mais de multiples exemples de l'objet à reconnaitre



Solutions- visuelle de clusters

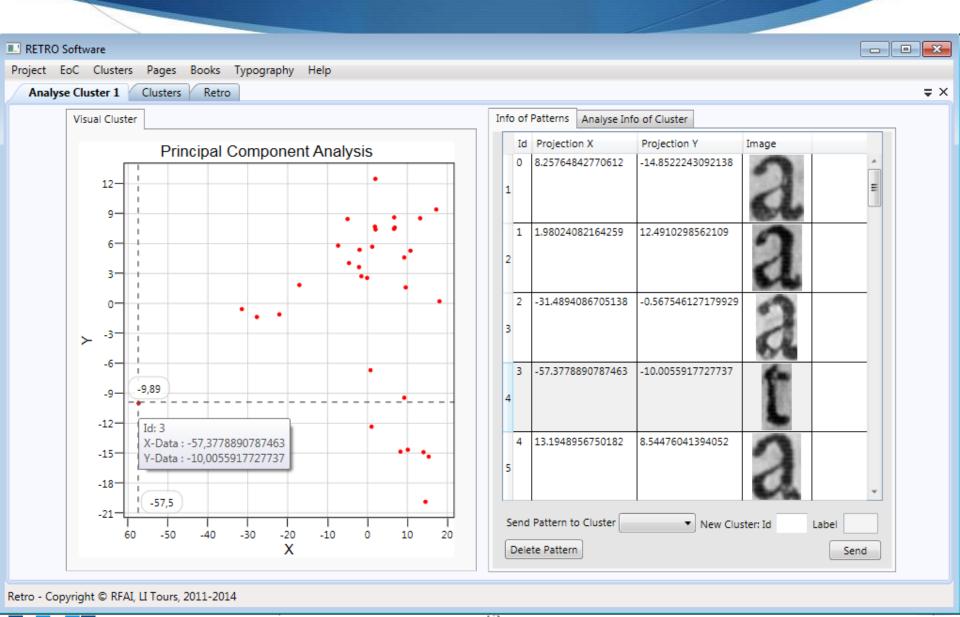


- La fonctionnalité « Analyse Cluster »:
 - Visuelle de clusters
 - ACP + coordonnées dynamique
 - Librairie: Accord.Net, DynamicDataDisplay
 - Optimisation de cluster
 - Manipulations: supprimer, envoyer à l'autre cluster



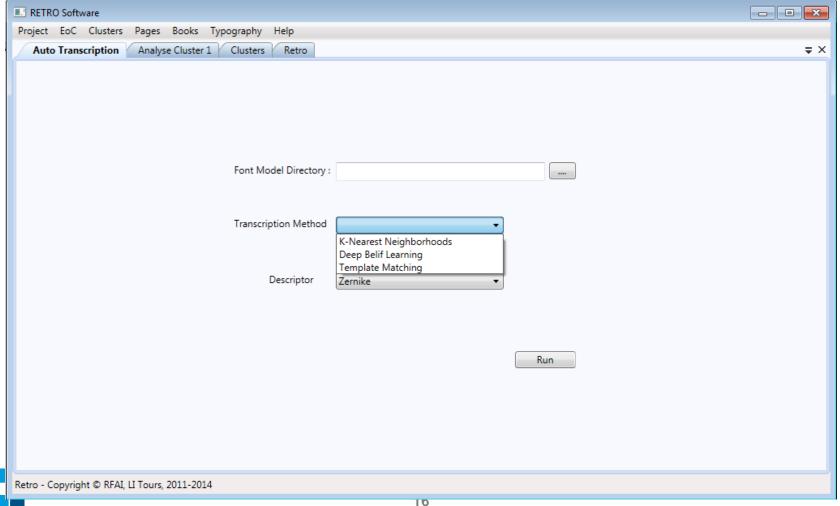
Solutions- visuelle de clusters







La fonctionnalité « Auto Transcription»





- KPlus Proche Voisins/KNearest Networks (KNNs)
 - L'apprentissage par analogie et l'apprentissage supervisé
 - Apprentissage paresseux
 - Simple, directe et efficace



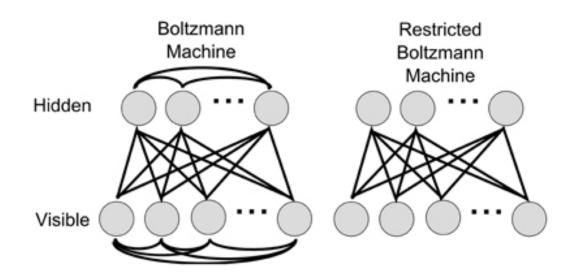


- Apprentissage en profondeur/Deep learning Networks
 - Profondeur = nb de couche
- Modèle probabiliste pour les architectures profondes:
 - Restricted Boltzmann machines(RBMs)
 - Deep Belief Networks(DBNs)





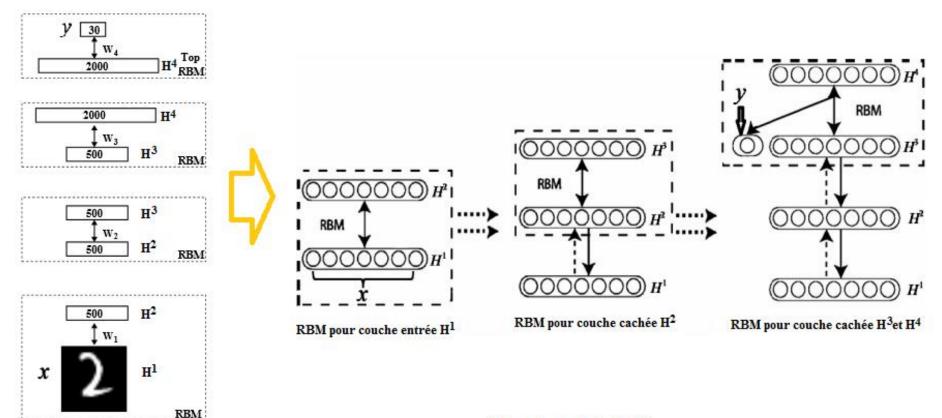
- Restricted Blotzmann Machine(RBM)
 - non-orienté, une couche d'entrée et seule couche cachée







DBNs avec RBM

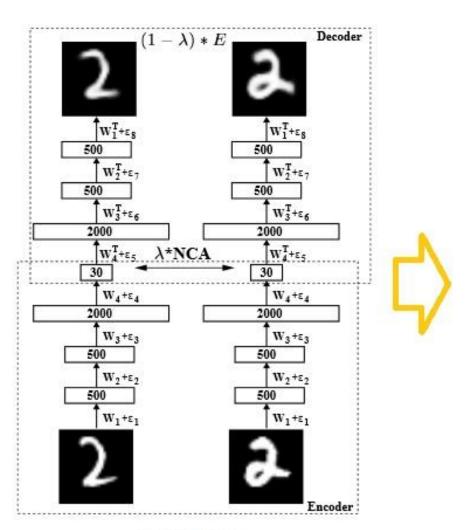




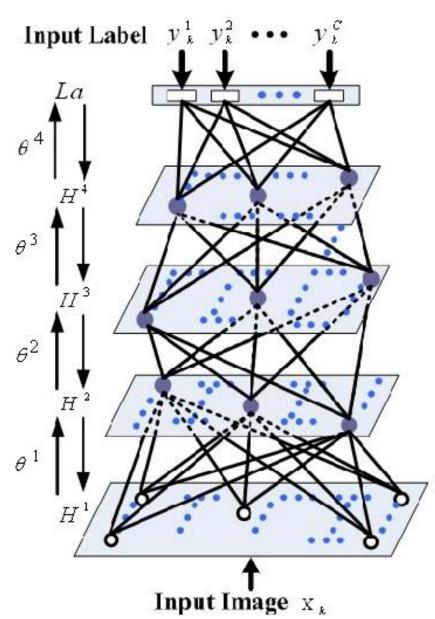


L'empilement du RBM



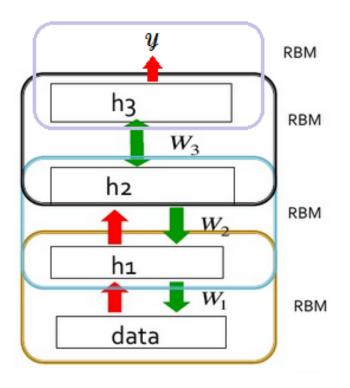


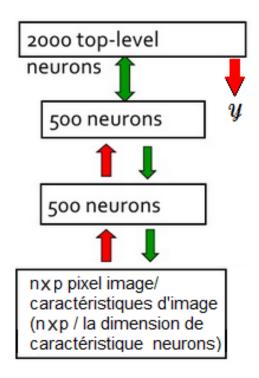
Fine-Tuning

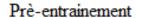




Structure Design du DBNs avec RBM







DBNs





Test

Méthode	Base d'app	Base de test	Tps d'app	Tps de test	Tps total	Reco. %
KNNs	70/11	5	13,0s	22,0s	35s	60%
	180/34	20	37,4s	35,2s	72,6s	30%
	473/83	70	61,9s	26,4s	88,3s	11%
DBNs	70/11	5	19min37s	12,9s	19min50s	0%
	180/34	20	3h2min	41,2s	3h3min	0%

- Forces et faiblesses
 - Approche tout sorte de fonction
 - Coûteux en apprentissage
 - Effet boite noire





- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- Solutions
- **Bilan**
- Gestion du projet
- Démonstration



Bilan



- Réalisation des objectifs :
 - Optimisation visuelle cluster
 - ✓ 2 méthodes de l'apprentissage automatique
- Bilan des tests
 - Analyse Cluster: 2000 patterns
 - Transcription : l'effet du KNNs est limit.
 DBNs n'est pas adaptable





- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- **▶** Solutions
- Bilan
- Gestion du projet
- Démonstration



Gestion du projet

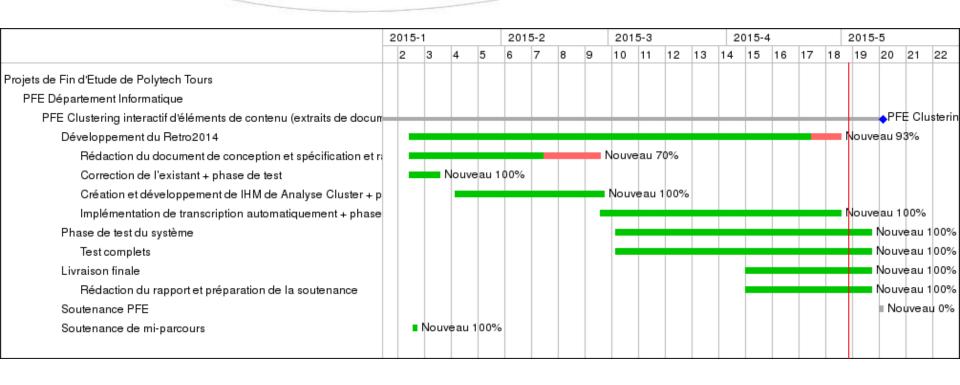


- Difficultés
 - Interactive visuelle de clusters
 - L'implémentation d'algorithme DBNs
- Amélioration
 - L'algorithme d'apprentissage automatique
 - La structure du logiciel



Gestion du projet





Gant Réel





- Contexte et objectif
- Analyse de l'existant
- Architecture finale
- **▶** Solutions
- Bilan
- Gestion du projet
- Démonstration



Démonstration



I. J. RETRO Software	0 2 2
Project EoC Clusters Pages Books Typography Help	
Di Companya di Com	
Retro - Copyright © RFAI, LI Yours, 2011-2014	





Merci de votre attention! Questions?

